

Duygu Analizi Benchmark'ı: BERT'ten LLM'e geçiş kararı

9.902 gerçek yorum, 7 sistem, 500 satırlık insan-denetimli referans seti.
Mevcut sistemin sorunu ölçüldü, adaylar yarıştırıldı, öneri netleşti.

%29,0

Mevcut sistem (BERT) doğruluğu

%92,8

Önerilen model (GLM 5.2) doğruluğu

\$0,24

GLM 5.2 ile 10.000 yorumun maliyeti

Şikayet haklıydı — ve kaynağı kesin olarak bulundu

Sorun

Üretimdeki etiketleri BERT üretmiş. BERT hattı çevrimdışı yeniden koşuldu; 9.902 kaydın **tamamında** üretim etiketiyle birebir aynı çıktı. Referans sete karşı doğruluğu yalnızca **%29**.

Kök neden

Veri seti ağırlıkla **destek yazışması** (takip soruları, kargo bilgilendirme e-postaları). BERT bu nötr işlem mesajlarını kitlesel olarak **POZITIF**'e yazıyor: POZITIF dediklerinin yalnızca **%2,2**'si gerçekten pozitif, NÖTR yakalama oranı **%3,8**.

Çözüm

GLM 5.2 önerilir: %92,8 doğruluk, 9.902 satırın tamamında sonuç (tek eksiksiz + en ucuz aday), 10 bin yorum **≈ \$0,24**. Model değişikliği artık süper-admin panelinden tek alanla yapılıyor.

Referans "doğrular" nasıl kuruldu?

- 1. Katmanlı örneklem:** 9.902 yorumdan, etiket × kategori dağılımını koruyan 500 satır seçildi (sabit tohum, tekrarlanabilir).
- 2. İki bağımsız güçlü model** (Claude Sonnet 5 + GPT-5.4) örnekleme ayrı ayrı etiketledi; **%90 anlaşma** (450/500).
- 3. 50 anlaşmazlık insan denetiminde** tek tek okunarak karara bağlandı. Nihai referans: NÖTR 320 · NEGATIF 174 · POZITIF 6.
- 4. Mevcut sistem doğrulandı:** BERT+kural katmanları çevrimdışı yeniden koşuldu ve kayıtlı üretim etiketleriyle 9.902/9.902 birebir örtüştü.
- 5. 5 aday model** aynı Türkçe komut ve 25'li paketlerle veri setinin tamamını sıfırdan etiketledi (sunucuda, kaynak sınırlı konteynerlerde).

Dipnot: Referans sette yalnızca 6 gerçek POZITIF var — bu veri destek yazışması ağırlıklı. Övgü ağırlıklı pazaryeri verisinde POZITIF sınıfı ayrıca doğrulanmalı.

Lig tablosu: 500 referans satırında

SİSTEM	DOĞRULUK	AĞIRLIKLİ F1	NEGATİF YAKALAMA	KAPSAM (9.902)	10K YORUM
Gemini 3.6 Flash	%95,2	0.952	0.913	%85	\$8,28
GLM 5.2 Öneri	%92,8	0.927	0.862	%100	\$0,24
DeepSeek v4 Pro	%89,4	0.900	0.851	%100	\$1,71
GPT-5.6 Luna	%88,5	0.888	0.980	%87	\$0,24
Claude Haiku 4.5	%87,5	0.883	0.933	%90	\$1,91
Mevcut sistem (BERT + katmanlar)	%29,0	0.282	0.730	%100	—

Kapsam: modelin 9.902 yorumun kaçına geçerli sonuç döndürdüğü. Gemini/GPT/Haiku kayıpları serbest-JSON çağrısından; üretimdeki yapılandırılmış çıktı yolu farkı azaltır.

Hata nerede yoğunlaşıyor?

Satırlar gerçek etiket, sütunlar sistemin kararı. Mevcut sistemde 320 gerçek NÖTR'ün 237'si POZITIF'e yazılmış.

Mevcut sistem (BERT) doğruluk %29			
GERÇEK ↓	POZ	NEG	NÖTR
POZITIF	6	0	0
NEGATIF	33	127	14
NÖTR	237	71	12

GLM 5.2 doğruluk %92,8			
GERÇEK ↓	POZ	NEG	NÖTR
POZITIF	2	0	4
NEGATIF	0	150	24
NÖTR	3	5	312

Gemini 3.6 Flash doğruluk %95,2 · kapsam %85			
GERÇEK ↓	POZ	NEG	NÖTR
POZITIF	2	0	2
NEGATIF	0	126	12
NÖTR	3	3	270

BERT'in "POZITIF" dedikleri

Üçü de üretimde POZITIF olarak kayıtlı; referans karar üçünde de NÖTR.

"Hi Destek Destek, Your FedEx Support Hub verification code is: 9241 ... Please ignore this email if you did not request it."

Otomatik doğrulama e-postası → **BERT: POZITIF** Gerçek: NÖTR

"merhaba, ürüne takip numarası verebilir misiniz teşekkürler."

Nazik bilgi talebi — "teşekkürler" BERT'i yanıltıyor → **BERT: POZITIF**
Gerçek: NÖTR

"This is Heyssel Canel from FedEx Logistics... regarding the FedEx package with the tracking number: 8899..."

Taşıyıcı bilgilendirmesi → **BERT: POZITIF** Gerçek: NÖTR

Sonuç: panodaki "olumlu yorum" oranı bugüne kadar yapay olarak şişti; gerçek şikayetlerin bir kısmı da POZITIF/NÖTR'e karışmış durumda.

Karar: GLM 5.2 ile geçiş, tek alan değişikliğiyle

Birincil GLM 5.2

%92,8 doğruluk · %100 kapsam · \$0,24 / 10k yorum. Fiyat/performans açık ara en iyi. NEGATIF kesinliği 0.968 — şikayet dediğine güvenilir. Süper-admin panelinde model alanını **z-ai/glm-5.2** yapmak yeterli.

Kalite şartsa Gemini 3.6 Flash

%95,2 doğruluk · \$8,28 / 10k. En isabetli aday; 34 kat maliyet ve bu koşuda %15 kapsam kaybıyla. Kritik raporlama dönemlerinde seçilebilir.

Şikayet kaçırmamak öncelikse GPT-5.6 Luna

NEGATIF yakalama 0.980 · \$0,24 / 10k. En yüksek şikayet duyarlılığı; karşılığında bir miktar fazla alarm üretir.

Yedek BERT + katmanlar

Yalnızca LLM erişilemediğinde acil geri düşüş olarak kalmalı; birincil sınıflandırıcı olarak emekli edilmeli.

Benchmark'la birlikte canlıya alınan 7 iş

- **Karar düzeltme 422 hatası** giderildi (çift JSON kodlama).
- **Yorum listesi filtreleri** detay sayfasına gidip dönünce artık korunuyor.
- **Yükleme limiti 10.000 → 25.000 satır** (işçi zaman aşımı payıyla birlikte).
- **Model + API anahtarı yönetimi süper admin'e taşındı** — kurumlar artık kendi modelini değiştiremez; iki yetki açığı kapatıldı, tam rol matrisi testlendi.
- **Analizler yorumun kendi tarihine göre** — dosyadaki "tarih" kolonu artık okunuyor; üç aylık tek yükleme ay-ay trend veriyor.
- **Katılım oranı** — kurum aylık işlem adedini girer, yorum/işlem yüzdesi süper adminin kurum bazında ayarladığı bantlarla derecelendirilir; tablo + CSV.
- **Kategori drill-down + Kök Neden Analizi** — ana kategori → alt kategori → LLM ile nokta atışı sebep; panoda tıklanabilir.

Durum: 783 test yeşil · deploy tamamlandı, migration 0038-0040 uygulandı · sistem varsayılanı ve Navlungo Test modeli GLM 5.2 — üretim yolunda canlı çağrıyla doğrulandı. Kalan tek karar: eski 9.902 yorumun yeni modelle yeniden analiz edilmesi.